Análise crítica de testes

Chatbot SecGrad | Sprint 3 | CInCoders | Revisão de 10/11/2026

1 Contexto e resultado principal

A análise compara testes produzidos com apoio de LLM e suas melhorias para três histórias: US-01, busca documental filtrada com fontes; US-02, fallback quando não há evidência suficiente; US-03, rascunho de e-mail para encaminhamento. A V2 exerce os 26 casos aprovados. Cobertura estrutural alta, porém, não certifica a qualidade semântica do corpus, a integração completa ou a força dos oráculos.

A IA usa Python, FastAPI, unittest e coverage.py 7.17.0 com branches. A US-01 foi medida sobre a produção e421ff9, com hashes idênticos entre V1 e V2. A refatoração posterior IA-REF-02 tem evidências separadas. O backend usa NestJS/TypeScript, Vitest e coverage-v8 4.1.11, Node 24.21.0. As US-02/03 foram medidas na baseline histórica 9d328dc, anterior à integração com /gerar. Regressões atuais não substituem essas suítes acadêmicas.

2 Projeto de referência

A matriz contém 15 critérios (5 + 4 + 6) e 26 casos (11 + 7 + 8). O inventário explicita 22 classes de entradas da IA e 22 do backend, além de 8 e 9 valores-limite por componente. Inclui entradas válidas/inválidas, fronteiras de quantidade e comprimento, limiar de distância e erros de contrato. A contagem é por variável/componente, sem produto cartesiano; não representa todas as combinações possíveis.

A elaboração da matriz teve assistência de LLM. Rafael informou aprovação coletiva e autorização da professora para essa forma de elaboração; a aprovação foi registrada no commit 97aa72f antes das gerações V1. Não se atribui autoria manual independente nem se criam atas individuais retrospectivas. O inventário atômico foi explicitado no fechamento, a partir das classes já descritas na matriz.

A US-01 usa coleção falsa. O backend V1 simula a busca; a V2 usa HTTP NestJS/Supertest local e simula fetch. São testes controlados: não medem Chroma real, precisão de recuperação, rede externa, UI, envio de e-mail ou provedor real de LLM.

Fontes e memória de cálculo: docs/testes/matriz-rastreabilidade.md, inventario-consolidado.md, us01-fechamento.md e evidencias-backend/. Os apêndices integrais acompanham o PDF no repositório.

Geração e preservação

3 Protocolo da LLM

Na IA, uma conversa nova recebeu US-01, critérios, módulos e framework, com instruções de partições, valores-limite e comentários por requisito, sem receber a matriz. A primeira saída foi preservada sem edição. Em 30/10/2026 foram executados 13 métodos: 11 passaram e dois concentraram nove falhas de subtestes, sem erro de importação. Não houve rodada de correção para aumentar cobertura na V1.

Na medição controlada posterior, o mesmo conteúdo V1 executou 13 métodos, com 11 aprovados e nove erros de subtestes nos outros dois: a produção já rejeitava dados inválidos por InvalidSearchResult. A diferença entre falha histórica e erro atual é registrada. O blob Git coincide com o commit original 0a75b77; o checkout Windows converte finais de linha para CRLF, mudando o hash bruto local. Manifestos históricos não foram reescritos; a verificação registra os hashes e a comparação de conteúdo normalizado.

No backend, a geração foi preservada em 02/11/2026 às 00:06:35 UTC (01/11, 21:06:35 em Fortaleza). Três arquivos geraram 65 instâncias Vitest, todas aprovadas em execução posterior. A V2 derivada manteve a produção e acrescentou HTTP e oráculos mais fortes, totalizando 105 instâncias aprovadas. O ZIP foi importado byte a byte: 138 arquivos, dos quais 137 estavam listados no manifesto e tiveram hashes conferidos.

Limitações do protocolo documentadas

O prompt integral preservado do backend nomeia as histórias e fornece código, mas não transcreve os critérios de aceitação nem pede explicitamente partições, limites e comentários por requisito, como o roteiro orientava. A análise posterior pode comparar com a matriz; isso não comprova que a LLM recebeu esse contexto na geração. A divergência permanece explícita e não é corrigida alterando a V1.

Os registros identificam Codex/agente GPT-6 conforme o ambiente informado, mas não disponibilizam snapshot exato. Não se deduz a versão de implantação. O pacote não contém transcrição integral específica do pedido de melhoria V2 do backend: há relatório, diff e resultados. Victor pode complementar apenas com o histórico real, se disponível. Os resultados não são descartados por essa limitação documental.

A V2 da IA corrigiu dois oráculos de origem inválida, acrescentou casos ausentes e foi ampliada de 17 para 21 métodos antes da IA-REF-02. Os pedidos de melhoria realizados neste chat estão registrados no log. Não se atribui a eles independência da matriz.

Apêndice de interação: llm-log.md liga o prompt e a saída integrais da IA em v1-ia-geracao.md e os arquivos originais do backend em evidencias-backend/01_V1/geracao/. A importação não reexecutou testes nem alterou código de produção.

Indicadores medidos

4 Resultados com escopos comparáveis

Indicador	IA V1 / V2	Backend V1 / V2
Unidade executada	13 / 21 métodos unittest	65 / 105 instâncias Vitest
Aprovados	11 / 21 métodos	65 / 105 instâncias
Falhas ou erros	V1: 2 métodos, 9 erros de subtestes; V2: 0	0 / 0
Não compilam/importam	0 / 0	0 / 0
Linhas, mesmo escopo	72/95 (75,79%) / 91/95 (95,79%)	45/45 (100%) / 45/45 (100%)
Branches, mesmo escopo	32/42 (76,19%) / 41/42 (97,62%)	53/53 (100%) / 53/53 (100%)
Critérios com oráculo direto	5/5 / 5/5, com CA-01.2 em erro na V1	8/10 + 2 parciais / 10/10
Casos completos, literal	10/11 / 11/11	7/15 / 15/15
Partições exercitadas	22/22 / 22/22	16/22 + 1 parcial / 22/22
Limites literais exercitados	8/8 / 8/8	3/9 / 9/9

Os critérios com oráculo direto somam 13/15 (86,67%) na V1 e 15/15 na V2; isso mede presença de verificação, não conformidade universal. Casos completos: 17/26 (65,38%), mais 7 parciais e 2 ausentes, contra 26/26. Partições: 38/44 (86,36%) contra 44/44; limites por componente: 11/17 (64,71%) contra 17/17. Erros não são removidos do denominador de exercício.

No backend, equivalência de partição admite 10 casos completos na V1; o recorte literal acima é mais estrito (7). Não misturar convenções. Instâncias parametrizadas do Vitest e métodos com subtestes do unittest não são unidades intercambiáveis: não se anuncia um total único de testes nem uma média simples de cobertura das duas stacks.

A V2 ampliada do backend inclui AiService e controller: 85/90 linhas (94,44%) e 108/113 branches (95,57%). Esses percentuais não representam queda em relação aos 100% da V1: o escopo passou de três para cinco arquivos. No escopo original o delta é zero, com teto já alcançado. A meta de crescimento estrito de branches é impossível nesse recorte; a melhoria funcional é demonstrada pelos novos oráculos e HTTP.

Nenhum teste sem asserção foi identificado nos corpos inspecionados; asserções fracas não são automaticamente triviais. Há dois grupos de integridade de retorno na IA e uma decisão de tratamento a esclarecer, não nove defeitos independentes. Backend: zero falhas funcionais observadas na V1; lacunas não são defeitos reproduzidos.

Análise dos testes

5 Técnicas funcionais e requisitos

A V1 da IA reconheceu as classes principais e os limites 0/1, mas não testou o rótulo exato Perfil Novo / Vigente nem o enriquecimento de metadados. A V1 do backend usou vizinhos 0.799999 e 0.800001, equivalentes em partição, porém diferentes dos literais aprovados 0.7999 e 0.8001; usou contexto vazio a distância 0 em vez de 0.1. A V2 reproduz os valores literais e acrescenta contexto/campos com comprimento útil 1.

No backend, CA-02.4 ficou parcial: a V1 injeta ServiceUnavailableException pronta, o que só comprova propagação. Não provoca timeout nem contrato inválido e não inspeciona HTTP seguro. CA-03.6 testa classe de exceção, sem corpo HTTP. A V2 executa AiService e controller reais com fetch controlado, verifica 503/504/502/400 e ausência de detalhes internos. Seus 40 testes HTTP ampliam a proteção sem alterar a baseline.

Linhas não equivalem a decisões verificadas

Na IA, enriquecer_metadados pode executar o for e o caminho codigo is not None sem executar o caminho oposto quando a lista contém Geral. O teste acrescentado test_documento_geral_na_lista cobre esse caminho. Na V2 final, o HTML ainda registra um branch descoberto e quatro linhas da abertura da coleção real não executadas; isso delimita o alcance da suíte.

No backend ampliado, a validação da consulta no AiService é um exemplo de decisão parcialmente coberta: requisições válidas executam sua avaliação, mas a rejeição de consulta inválida não é exercitada nessa seleção histórica. O HTML aponta o branch faltante. Os três arquivos originais, já em 100%, não devem receber um exemplo inventado de branch descoberto.

Oráculos e testes potencialmente fracos

Na IA, os dois métodos problemáticos exigiam sucesso com página inválida ou distância não finita na origem. O contrato não determinava recuperação automática. A correção de produção passou a rejeitar a origem com HTTP 502; V2 afirma essa rejeição, sem inventar página ou distância. É correção de comportamento, distinta da posterior refatoração.

No backend, brancos eram comparados a outra saída do mesmo gerador; classe BadRequestException não provava a mensagem segura; flag de fallback não garantia template completo. V2 acrescenta literais, corpo integral e inspeção de dados internos. Assuntos mistos herdados seguem a prioridade implementada, mas a matriz não aprova desempate: não são novos requisitos. SecGrad coincide com o padrão, então um teste isolado desse setor pode passar mesmo com regra específica removida. São riscos de falso positivo identificados por inspeção; não houve teste de mutação.

Melhorias e conclusão

6 O que mudou na V2

Lacuna	Melhoria e efeito observado
Alias e metadados da IA	Rótulo exato, metadados gerais/multicurso e perfis. Fecha CT-01.03 e caminhos de enriquecimento.
Origem inválida da IA	Oráculo de rejeição, HTTP 502, listas inconsistentes e tipos inválidos. Não altera V1.
Status genérico 4xx	V2 da IA acrescenta 422 exato. Evita aprovação por status errado.
Falhas técnicas do backend	AiService real e HTTP local com fetch simulado. Fecha CT-02.05/06/07.
Template e dados	Corpo e marcadores literais, ausências individuais e HTTP 400 seguro. Fecha obrigações parciais de CT-03.06/08.
Limites do backend	0.7999/0.8/0.8001 e comprimentos mínimos literais. Mantém 100% estrutural original, melhora evidência funcional.

7 Conclusão e alcance

A equipe usaria LLM para propor testes e explorar classes de entrada, preservando requisitos externos como oráculo e revisando casos contra eles. A evidência mostra por que quantidade e cobertura não bastam: 65 testes e 100% de branches no backend deixavam obrigações HTTP incompletas. O ganho da V2 está na ligação entre requisito, entrada, resultado e fronteira realmente exercitada.

A IA teve aumento controlado de branches de 76,19% para 97,62%; o backend permaneceu no teto de 100% no escopo original. O atendimento literal da meta de aumento do backend requer a ressalva de teto e eventual alinhamento com o monitor, sem degradar V1, trocar denominadores ou inventar um delta.

As suítes e medições históricas foram preservadas. A base pós-OCR tem 21 documentos e 6.811 trechos, com sete pares curso/perfil auditados. EC anterior 22 continua sem texto: inspeção visual e relato de Ricardo identificam contracapa com etiqueta administrativa, sem conteúdo curricular corrido; exclusão justificada, não OCR declarado bem-sucedido. Quatro páginas de SI ganharam texto, cuja fidelidade Ricardo relatou conferir.

No fechamento de 10/11, Node 24.22.1: 256 testes correntes do backend, 34 e2e mais dois opt-in, 20 da IA, 21 V2 da US-01 e 12 do cliente UI aprovados; seleção de 52 é subconjunto. Build e lint passaram, com dois avisos preexistentes. BACK-REF-03 tem mesma regressão corrente 256/256 antes/depois e commit próprio; não substitui V2 acadêmica histórica. AppTest com HTTP real confirmou aviso mock, página e trecho literal. Sem navegador ou LLM real.

Benchmark: 25 perguntas, 50 chamadas comparando limiares. Com 0,8: 15/25 decisões de fallback conforme expectativa, dez aceitações fora do escopo e nenhuma recusa dos 15 casos dentro. Com 0,5: 18/25, sete aceitações externas. Sete controles recuperaram o PPC esperado. Pergunta curta carburador e frase completa não equivalem. Não há limiar calibrado; mantém-se 0,8 provisório, registra-se QA-01 e não se afirma precisão de resposta acadêmica com mock. Evidências, oráculos e limitações: fechamento-final-20261110/.

Apêndices e evidências entregues com o PDF

A: matriz-rastreabilidade.md; B: llm-log.md e suas referências integrais; memória de cálculo: inventario-consolidado.md e indicadores-consolidados.json. Índice e instruções: CONSOLIDACAO-SPRINT3.md. Todos ficam na mesma pasta docs/testes e devem acompanhar este PDF.

HTMLs e manifestos: consulte CONSOLIDACAO-SPRINT3.md. IA em relatorios/us01-controlado/; backend em evidencias-backend/01_V1/ e 02_V2/. Os inventários e registros originais acompanham os relatórios.